

STUDI KASUS

ANALISIS

MULTIVARIAT


DATA KUALITAS AIR

ANALISIS DATA
STATISTIK B




Analisis Kualitas Air

Penilaian kualitas air dan identifikasi sumber Sungai Shuangji (Tiongkok) menggunakan metode statistik multivariat





Pendahuluan



Gambar 1. Peta wilayah studi dan lokasi pemantauan kualitas air.

<https://doi.org/10.1371/journal.pone.0245525.g001>

Sungai Shuangji adalah anak Sungai Huai yang terletak di Xinmi, Provinsi Henan, Tiongkok, dengan panjang sekitar 57 km dan daerah aliran seluas 868 km². **Sungai ini merupakan daerah aliran tertutup tanpa suplai air eksternal, sehingga sangat rentan terhadap pencemaran.** Saat ini, **Sungai Shuangji tercemar, dengan sumber air utamanya berasal dari limbah domestik dan industri.** Sungai ini berperan penting dalam pembuangan limbah serta menjadi sumber air untuk kebutuhan rumah tangga, industri, dan irigasi. Oleh karena itu, pemantauan kualitas air secara rutin diperlukan untuk pengelolaan sungai yang efektif.



Pendahuluan

1


Pengambilan sampel dalam penelitian ini dirancang untuk mencakup lokasi-lokasi kunci yang berpengaruh terhadap kualitas air sungai, termasuk anak-anak sungai utama dan titik-titik masuk air. **Sebanyak 14 titik pemantauan ditetapkan**, meliputi **6 titik di anak sungai (T1-T6) dan 8 titik di badan utama Sungai Shuangji (M1-M8)**.

2

Titik-titik di dekat perkotaan (M1-M3 dan T1-T3) utamanya dipengaruhi oleh **limbah domestik**, sedangkan titik-titik di zona industri (M4, M5, T4, T5) banyak terpapar **limbah industri kertas**. Titik-titik hilir sungai (M6-M8) terletak di area yang **tidak menerima aliran eksternal tambahan**.

3

Data kualitas air dikumpulkan selama dua tahun, dari 2018 hingga 2020. **Parameter yang dipantau meliputi 19 indikator fisik dan kimia**, seperti pH, oksigen terlarut (DO), kebutuhan oksigen kimia (COD), amonia nitrogen ($\text{NH}_3\text{-N}$), fosfor total (TP), logam berat (seperti Cu, Zn, Cd, As, Hg), dan bahan pencemar organik lainnya.



Metode Penelitian

Dalam penelitian ini, seluruh **data dianalisis** menggunakan berbagai **teknik analisis statistik multivariat** untuk mengidentifikasi parameter-parameter yang menyebabkan perubahan kualitas air pada skala **temporal dan spasial**. Pengelolaan pencemaran sungai secara efektif memerlukan penjelasan terhadap sejumlah besar data kualitas air yang kompleks. Oleh karena itu, **analisis multivariat** digunakan sebagai pendekatan penting untuk memahami informasi tersebut secara lebih mendalam.



VARIABEL



No.	Variabel	Definisi
1	pH	Ukuran keasaman air akibat limbah domestik dan industri.
2	Dissolved Oxygen (DO)	Oksigen terlarut yang mencerminkan kesehatan ekosistem sungai.
3	Chemical Oxygen Demand (COD)	Indikator polusi organik dari limbah domestik dan industri.
4	Ammonical Nitrogen (NH ₃ -N)	Amonia dari limbah domestik dan urban.
5	Total Phosphorus (TP)	Nutrien dari limbah rumah tangga dan pertanian.
6	Chemical Oxygen Demand (Mn) (CODMn)	Indikator bahan organik mudah teroksidasi.
7	Fluoride (F)	Fluorida dari aktivitas industri dan tambang.
8	Petroleum Oil (Oil)	Kontaminasi minyak dari industri dan transportasi.
9	Linear Alkylbenzene Sulfonates (LAS)	Surfaktan dari limbah deterjen domestik.
10	Copper (Cu)	Logam berat dari pabrik kertas dan pertambangan.
11	Zinc (Zn)	Logam dari industri logam dan manufaktur.
12	Cadmium (Cd)	Logam berat beracun dari industri metalurgi.
13	Arsenic (As)	Polutan dari buangan industri dan batuan alam.
14	Mercury (Hg)	Polutan berat dari pertambangan dan industri.
15	Hexavalent Chromium (Cr ⁶⁺)	Polusi logam berat dari industri kimia dan logam.
16	Total Cyanide (CN)	Sianida dari limbah kimia beracun.
17	Volatile Phenol (VP)	Senyawa organik beracun dari industri kimia.
18	Sulfide (S)	Polutan dari dekomposisi organik dan industri.
19	Selenium (Se)	Unsur logam dari proses metalurgi dan tambang.



Struktur Data



No	Lokasi	X1	X2	..	X18	X19
t1	Lokasi 1	X1 (1 1)	X2 (1 1)	..	X18 (1 1)	X19 (1 1)
t2	Lokasi 2	X1 (1 2)	X2 (1 2)	..	X18 (1 2)	X19 (1 2)
:	:	:	:	:	:	:
t12	Lokasi 14	X1 (12 14)	X2 (12 14)	..	X18 (12 14)	X19 (12 14)

Keterangan:

$X_i(j\ t)$ = data pengamatan kualitas air

i = variabel yang digunakan; $i = 1, 2, 3, \dots, 19$

j = lokasi pengamatan; $j = 1, 2, \dots, 14$

t = waktu pengamatan tiap bulan; $t = 1, 2, \dots, 12$



Karakteristik Data

Daftar Variabel

	Variabel	10	Cr6+
0	Waktu	11	LAS
1	NO.	12	Cu
2	PH	13	Zn
3	DO	14	Cd
4	COD	15	As
5	NH3-N	16	Hg
6	TP	17	CN
7	CODMn	18	VP
8	F	19	S
9	Oil	20	Se

Data memiliki 21 variabel, yang terdiri dari 1 variabel waktu, 1 variabel titik lokasi pengambilan sampel ("NO."), dan 19 parameter kualitas air.

Dimensi Data

(168, 21)

Data terdiri dari 168 baris dan 21 kolom.

Tipe Data

```
Data columns (total 21 columns):
#  Column  Non-Null Count  Dtype
---  -
0  Waktu    168 non-null    object
1  NO.      168 non-null    object
2  PH       168 non-null    float64
3  DO       168 non-null    float64
4  COD      168 non-null    int64
5  NH3-N    168 non-null    float64
6  TP       168 non-null    float64
7  CODMn    168 non-null    float64
8  F        168 non-null    float64
9  Oil      168 non-null    float64
10 Cr6+     168 non-null    float64
11 LAS     168 non-null    float64
12 Cu      168 non-null    float64
13 Zn      168 non-null    float64
14 Cd      168 non-null    float64
15 As      168 non-null    float64
16 Hg      168 non-null    float64
17 CN      168 non-null    float64
18 VP      168 non-null    float64
19 S       168 non-null    float64
20 Se      168 non-null    float64
dtypes: float64(18), int64(1), object(2)
memory usage: 27.7+ KB
```

Semua parameter untuk mengukur kualitas air memiliki tipe data yang telah sesuai.



Preprocessing Data

Duplicate Data

```
# Cek duplicate data
df.duplicated().sum()

np.int64(0)
```

Tidak terdapat duplikasi pada data


Missing Value

```
# Cek Missing Value
df.isnull().sum()
```


	0	Cr6+	0
Waktu	0	LAS	0
NO.	0	Cu	0
PH	0	Zn	0
DO	0	Cd	0
COD	0	As	0
NH3-N	0	Hg	0
TP	0	CN	0
CODMn	0	VP	0
F	0	S	0
Oil	0	Se	0

Tidak terdapat missing value pada data

Outlier



Terdapat outlier pada variabel DO, Cd, Hg, VP, S, dan Se. Outlier tersebut tidak ditangani untuk menjaga keaslian data, karena outlier dapat memberikan informasi penting tentang kondisi ekstrem atau perubahan yang relevan dalam kualitas air.



Exploratory Data Analysis (EDA)



Statistika Deskriptif




	count	mean	std	min	25%	50%	75%	max
PH	168.0	7.649226	0.214766	7.27000	7.47000	7.66500	7.82250	8.3100
DO	168.0	8.398095	0.561424	6.80000	8.10000	8.50000	8.80000	9.7000
COD	168.0	20.577381	10.062974	4.00000	12.00000	21.00000	28.00000	44.0000
NH3-N	168.0	1.057262	0.413162	0.33000	0.73000	0.97000	1.38500	2.2200
TP	168.0	0.196369	0.090298	0.03000	0.13000	0.17500	0.26000	0.4400
CODMn	168.0	5.725595	1.711882	2.40000	4.60000	5.70000	7.20000	9.9000
F	168.0	0.679643	0.157506	0.38000	0.57750	0.66000	0.82000	1.1000
Oil	168.0	0.105417	0.050088	0.02000	0.06000	0.08000	0.16000	0.2400
Cr6+	168.0	0.016292	0.004458	0.00600	0.01400	0.01700	0.02000	0.0260
LAS	168.0	0.201905	0.066746	0.04000	0.15000	0.21000	0.26000	0.3200
Cu	168.0	0.042917	0.016171	0.02000	0.03000	0.04000	0.05000	0.0800
Zn	168.0	0.041548	0.010029	0.02000	0.03000	0.04000	0.05000	0.0700
Cd	168.0	0.000282	0.000080	0.00010	0.00020	0.00030	0.00030	0.0005
As	168.0	0.002360	0.000822	0.00070	0.00180	0.00230	0.00310	0.0038
Hg	168.0	0.000139	0.000055	0.00005	0.00009	0.00013	0.00016	0.0003
CN	168.0	0.010381	0.003947	0.00400	0.00700	0.00900	0.01300	0.0190

Berdasarkan statistika deskriptif tersebut dapat diambil beberapa kesimpulan yaitu :

- Semua parameter memiliki jumlah observasi yang sama (168 data)
- Rata-rata nilai PH untuk seluruh lokasi adalah sebesar 7,64 satuan.
- Nilai maksimum COD bahkan mencapai 44 mg/L, yang relatif tinggi dan menunjukkan kemungkinan adanya pencemaran organik berat di beberapa titik.
- Senyawa seperti Cr^{6+} , Hg, Cd, CN, As, dan lainnya memiliki rata-rata yang sangat kecil dan standar deviasi rendah, menunjukkan bahwa secara umum kadar pencemar tersebut rendah dan tidak banyak variasi antar sampel.
- Distribusi data cenderung simetris dan homogen, ditunjukkan dari nilai kuartil yang berdekatan dan tidak menunjukkan outlier ekstrem pada sebagian besar parameter, kecuali beberapa seperti COD dan $\text{NH}_3\text{-N}$.



Distribusi Tiap Variabel Pada Data




Berdasarkan histogram dari masing-masing parameter kualitas air sebagai berikut :

- **Parameter yang berdistribusi normal** yaitu **pH, TP, CODMn, F, NH₃-N, dan Zn** yang mengindikasikan bahwa variabel tersebut memiliki sebaran data yang wajar dan bisa diasumsikan normal untuk keperluan analisis statistik parametrik.
- Parameter seperti **DO, COD, Oil, LAS, dan Cr⁶⁺** terlihat **agak miring ke kanan (positively skewed)** artinya lebih banyak data di sisi rendah dan ada beberapa nilai ekstrem tinggi.
- Parameter yang tidak berdistribusi normal seperti **Cd, As, Hg, CN, Se, VP, S** artinya data tersebar tidak merata dan didominasi nilai-nilai kecil. Namun ini wajar untuk parameter toksik yang umumnya hanya muncul dalam jumlah kecil atau hanya terdeteksi di beberapa lokasi.



Korelasi Antar Variabel



Berdasarkan heatmap korelasi yang dihasilkan sebagai berikut :
Korelasi positif cukup kuat pada

- COD dengan NH₃-N (0.54) dan Cr₆+ (0.54), mengindikasikan bahwa ketika kadar COD meningkat, kemungkinan besar kadar amonia dan Cr₆+ juga meningkat ini konsisten karena semuanya indikator pencemaran organik dan anorganik.
- CODMn dengan NH₃-N (0.53) dan TP (0.48), menunjukkan keterkaitan antara bahan organik dan nutrien dalam air.
- Cu dengan S (0.58), mungkin menunjukkan sumber pencemaran yang sama, seperti limbah industri atau logam berat.
- CN dengan VP (0.61), dua zat beracun yang sering berasal dari limbah kimia atau industri.

Korelasi negatif lemah ditemukan antara beberapa parameter seperti pH dengan CN (-0.32) dan NH₃-N dengan F (-0.31), namun tidak cukup kuat untuk disebut hubungan linier signifikan.



Cluster Analysis (CA)



Cluster Analysis (CA)

Pengertian:



Cluster Analysis adalah **teknik statistik yang digunakan untuk mengelompokkan objek atau data berdasarkan kesamaan karakteristiknya**. Objek-objek dalam satu kelompok (cluster) akan memiliki kemiripan yang tinggi satu sama lain dan perbedaan yang besar dengan objek dari kelompok lain.

Tujuan:

- Mengidentifikasi pola-pola kelompok waktu atau lokasi berdasarkan parameter kualitas air.
- Menentukan titik atau waktu pemantauan yang representatif, sehingga efisien untuk pengawasan kondisi sungai.



Analisis Cluster Spasial



Setelah data distandarisasi (agar skala data sama), data digabung menjadi group berdasarkan rata-rata dari tiap lokasi.


Diperoleh kluster spasial sebagai berikut :

Kluster 1 : **M2, M3, T2, T3, T4, T5**


Kluster 2 : **M4, M5, M6, M7, M8, T6**

Kluster 3 : **M1 dan T1**

	PH	DO	COD	NH3-N	TP	CODMn	F	O11	Cr6+	LAS	Cu	Zn	Cd	As	Hg	CN	VP	S	Se
NO.																			
M1	-1.277866	-2.723320	1.240478	1.867456	2.453740	1.842557	-0.902664	1.807893	0.405592	2.025612	1.226642	2.245217	-0.838548	1.225141	1.311989	1.936865	1.814313	1.779760	1.253382
M2	-0.048591	1.016176	-0.640823	-0.554118	0.061323	-1.435196	1.197635	-0.120526	-1.831310	1.279334	0.876173	-0.853815	-1.011190	-0.354877	0.456934	0.462467	-0.802956	0.625475	-0.465784
M3	1.980309	0.415673	-0.390708	0.703807	0.381838	0.245703	-0.512186	-1.172391	-0.307267	-0.753631	-0.245328	1.359779	0.542590	-0.723548	0.615278	-0.755515	0.098071	-0.528810	-0.110094
M4	0.727165	0.606742	0.783746	0.461381	0.393285	0.311738	-0.275532	-0.471148	0.798894	0.533056	-0.035047	-0.189737	0.369948	0.786247	0.900296	-0.018316	1.728501	1.461336	1.549790
M5	2.028048	-1.003698	1.501468	-0.395194	-0.041700	0.575879	-0.074377	-0.602631	0.405592	-0.290424	0.105141	-0.632456	1.233159	1.207585	0.551940	1.520187	-0.416802	-0.409402	1.194101
M6	-0.549849	-0.730742	0.751122	-0.516408	-0.751412	0.083616	0.901819	1.281960	1.265939	0.249985	-0.175235	0.474342	1.751086	0.610690	-0.366452	0.782988	0.140977	-0.887037	-0.228658
M7	-0.406632	-0.075648	0.631502	-0.651089	-0.568260	0.473825	0.955066	0.975166	0.774312	0.121316	-0.525704	-0.853815	0.542590	0.575578	-0.588133	0.334258	0.355507	-0.489007	0.008469
M8	0.786838	1.474742	0.392261	-1.033585	-0.602601	0.443809	0.700663	0.821769	0.331848	0.069849	-1.296736	-1.739253	-0.320621	0.101573	-1.063163	-0.659358	-0.717144	-1.086052	-0.643629
T1	-0.323090	0.524855	0.827244	1.064754	1.606664	0.984098	1.156221	0.098612	0.749731	1.021997	2.488330	0.474342	-0.493264	0.347353	0.425265	1.039405	1.471064	1.938972	0.897693



Analisis Cluster Spasial



Gambar 1. Peta wilayah studi dan lokasi pemantauan kualitas air.

<https://doi.org/10.1371/journal.pone.0245525.g001>

Diperoleh kluster spasial sebagai berikut :

Kluster 1 : **M2, M3, T2, T3, T4, T5**



Kluster 2 : **M4, M5, M6, M7, M8, T6**

Kluster 3 : **M1 dan T1**

Titik-titik di dekat perkotaan (**M1-M3 dan T1-T3**) utamanya dipengaruhi oleh limbah domestik, sedangkan titik-titik di zona industri (**M4, M5, T4, T5**) banyak terpapar limbah industri kertas. Titik-titik hilir sungai (**M6-M8**) terletak di area yang tidak menerima aliran eksternal tambahan



Analisis Cluster Temporal



Setelah data distandarisasi (agar skala data sama), data digabung menjadi group berdasarkan rata-rata dari tiap waktu.

Diperoleh kluster temporal sebagai berikut :

Kluster 1 : **Juni, Juli, Agustus, September (Musim Panas - Musim Gugur)**

Kluster 2 : **Oktober, November, Desember, Januari (Musim Gugur - Musim Dingin)**

Kluster 3 : **Maret, April, Mei (Musim Semi)**

	PH	DO	COD	NH3-N	TP	CODMn	F	Oil	Cr6+	LAS	Cu	Zn	Cd	As	Hg	CN	VP	S	Sr
Waktu																			
2019.08	-1.224247	0.007631	1.489388	-0.543943	1.704996	1.090958	-0.314485	-1.625473	1.711951	-0.731865	1.153426	0.509110	1.466439	0.291651	1.582172	0.832743	0.650791	-0.239420	-0.912811
2019.09	-1.895512	1.810442	0.289881	1.102027	0.466875	1.150628	2.081594	0.147770	0.347588	-2.104113	-0.338430	2.845026	-0.488813	1.197009	0.371905	0.134708	-0.433861	-0.239420	1.169940
2019.10	0.830541	-0.793619	-0.823947	-0.888975	0.374016	1.007421	0.284534	1.399471	-0.626957	-1.280764	-1.415882	-0.029948	-1.140563	-1.397449	-0.970735	1.089914	1.807754	1.017535	-0.912811
2019.11	-0.143049	0.001908	-1.389429	-0.934225	0.033532	-0.603657	-1.272917	1.086546	-0.665939	0.365933	-0.338430	-0.569005	-0.814688	-2.451448	-0.460154	-0.783758	-1.120807	-0.957680	-1.105655
2019.12	1.266094	1.896291	-0.703996	-1.019068	-0.740293	1.413174	2.081594	-0.686697	-1.055757	-0.038519	-1.167240	-1.108063	-1.792314	-0.897475	-1.103108	-1.738964	-1.301583	-1.765723	0.822811
2020.01	0.687064	-0.164065	-2.023454	-1.086943	-1.421260	-1.355493	-0.254583	-0.373772	-1.055757	0.640382	-1.250120	-0.209633	-0.488813	0.264626	-0.895093	-1.151145	-0.976187	-1.227028	0.899955
2020.03	0.897155	0.236559	0.478375	1.531902	-1.049824	-0.878137	-0.524142	-1.208239	-0.626957	0.625937	-0.504192	-0.209633	-0.162938	0.588933	-0.781631	-0.636804	-0.542326	0.029928	1.324211
2020.04	0.989390	-0.392994	0.546918	1.826027	-0.802199	-0.627525	-0.584044	-0.165155	-0.432048	0.611493	-0.338430	-0.029948	-0.162938	0.521369	-0.724900	-0.489849	-0.542326	-0.329203	1.555635
2020.05	-0.194291	-1.451788	0.821091	0.762652	-0.956965	-1.045211	-0.224632	0.147770	-0.237139	0.958166	0.324617	-0.389319	0.162938	0.778112	-0.592527	-0.673542	-0.578481	0.927753	-0.719965
2020.06	-0.081560	-0.621922	0.426967	-0.204568	0.312110	-0.782665	-0.014975	1.086546	-0.003248	1.015945	1.319188	-0.389319	1.140563	0.359215	0.920307	1.236869	1.084652	1.376666	-0.604255
2019.07	-1.475331	-1.165627	1.043857	-0.549599	1.828808	1.090958	-0.554093	-1.103931	2.257696	-1.064094	1.153426	0.688796	1.466439	0.291651	1.733455	0.832743	0.650791	-0.149638	-0.912811
2020.07	0.343746	0.637184	-0.155650	0.004714	0.250204	-0.460450	-0.703848	1.295163	0.386569	1.001500	1.402069	-1.108063	0.814688	0.453805	0.920307	1.347085	1.301583	1.556231	-0.604255

Musim Semi : Maret – Mei

Musim Dingin : Desember – Februari

Musim Panas : Juni– Agustus

Musim Gugur : September – November



Discriminant Analysis (DA)



Discriminant Analysis (DA)

Pengertian:

Discriminant Analysis adalah **metode statistik yang digunakan untuk menentukan variabel mana yang membedakan dua atau lebih kelompok objek atau peristiwa.**

Tujuan:

- Menilai variabel-variabel yang paling berkontribusi dalam membedakan kelompok



Pengujian Asumsi

1. Uji Normalitas Multivariat Menggunakan Royston's Test

Uji normalitas multivariat digunakan untuk menentukan apakah sebuah dataset multivariat mengikuti distribusi normal multivariat.

Hipotesis :

H0 : Data mengikuti distribusi normal multivariat.

H1 : Data tidak mengikuti distribusi normal multivariat.

Taraf Signifikansi : 0.05

Daerah kritis :

Tolak H0 jika $p.value < 0.05$

Statistik Uji :

```
=== Uji Normalitas Multivariat (Royston's Test) ===  
Statistik H      : 1.1293  
p-value          : 0.0000  
Hasil Interpretasi: Data TIDAK berdistribusi normal
```

Keputusan & Kesimpulan :

Dengan tingkat signifikansi 0,05 dan nilai p-value sebesar 0,0, maka keputusan yang diambil adalah **Tolak H0**, yang berarti data tidak mengikuti distribusi normal multivariat.



Pengujian Asumsi

2. Uji Brown-Forsythe untuk Homogenitas Varians

Uji Brown-Forsythe digunakan untuk menguji homogenitas varians antar kelompok. Metode ini lebih robust terhadap pelanggaran normalitas.

Hipotesis :

H₀ : Varians antar kelompok sama.

H₁ : Ada perbedaan varians.

Taraf Signifikansi : 0.05

Daerah kritis :

Tolak H₀ jika p.value < 0.05

Statistik Uji :

Hasil Uji Brown-Forsythe untuk Homogenitas Varians:

	Variabel	Statistik	p-value
0	PH	0.375972	9.755931e-01
1	DO	2.414716	5.436403e-03
2	COD	1.995381	2.443438e-02
3	NH ₃ -N	1.105792	3.580728e-01
4	TP	0.966204	4.871545e-01
5	CODMn	3.204437	2.729530e-04
6	F	1.991014	2.480696e-02
7	Oil	3.270241	2.116842e-04
8	Cr6+	2.218822	1.109201e-02
9	LAS	0.895901	5.587964e-01
10	Cu	0.705989	7.554268e-01
11	Zn	0.860636	5.956602e-01
12	Cd	2.312124	7.914293e-03
13	As	0.969923	4.834617e-01
14	Hg	2.498794	3.984121e-03
15	CN	15.388278	6.862569e-22
16	VP	2.331349	7.378910e-03
17	S	3.540776	7.416696e-05
18	Se	4.682788	8.801495e-07



Pengujian Asumsi

2. Uji Brown-Forsythe untuk Homogenitas Varians

Statistik Uji :

Interpretasi:			
	Variabel	p-value	Interpretasi
0	PH	9.755931e-01	Gagal tolak H0 (varians homogen)
1	DO	5.436403e-03	Tolak H0 (varians berbeda)
2	COD	2.443438e-02	Tolak H0 (varians berbeda)
3	NH3-N	3.580728e-01	Gagal tolak H0 (varians homogen)
4	TP	4.871545e-01	Gagal tolak H0 (varians homogen)
5	CODMn	2.729530e-04	Tolak H0 (varians berbeda)
6	F	2.480696e-02	Tolak H0 (varians berbeda)
7	Oil	2.116842e-04	Tolak H0 (varians berbeda)
8	Cr6+	1.109201e-02	Tolak H0 (varians berbeda)
9	LAS	5.587964e-01	Gagal tolak H0 (varians homogen)
10	Cu	7.554268e-01	Gagal tolak H0 (varians homogen)
11	Zn	5.956602e-01	Gagal tolak H0 (varians homogen)
12	Cd	7.914293e-03	Tolak H0 (varians berbeda)
13	As	4.834617e-01	Gagal tolak H0 (varians homogen)
14	Hg	3.984121e-03	Tolak H0 (varians berbeda)
15	CN	6.862569e-22	Tolak H0 (varians berbeda)
16	VP	7.378910e-03	Tolak H0 (varians berbeda)
17	S	7.416696e-05	Tolak H0 (varians berbeda)
18	Se	8.801495e-07	Tolak H0 (varians berbeda)

Keputusan & Kesimpulan :

Untuk variabel **PH, NH3-N, TP, LAS, Cu, Zn, As** keputusannya adalah Gagal Tolak H0 karena p.value > 0.05 yang berarti varians homogen. Sedangkan untuk variabel **DO, COD, CODMn, F, Oil, Cr6+, Cd, Hg, CN, VP, S, Se** keputusannya adalah Tolak H0 karena p.value < 0.05 artinya varians berbeda.

Oleh karena itu pada analisis ini akan menggunakan **Linear Discriminant Analysis** (LDA), terutama karena data jumlahnya besar (banyak observasi), dan LDA cukup robust terhadap pelanggaran asumsi moderat.



ANALISIS DISKRIMINAN SPASIAL

Cross-validation accuracy: 0.65

Confusion Matrix (Teks):

```
[[12  0  0  0  0  0  0  0  0  0  0  0  0  0]
 [ 0 12  0  0  0  0  0  0  0  0  0  0  0  0]
 [ 0  0 12  0  0  0  0  0  0  0  0  0  0  0]
 [ 0  0  0 12  0  0  0  0  0  0  0  0  0  0]
 [ 0  0  1  0 11  0  0  0  0  0  0  0  0  0]
 [ 0  0  0  0  0 10  1  1  0  0  0  0  0  0]
 [ 0  0  0  0  1  0  9  2  0  0  0  0  0  0]
 [ 0  0  0  0  0  0  1 11  0  0  0  0  0  0]
 [ 0  0  0  0  0  0  0  0 12  0  0  0  0  0]
 [ 0  0  0  0  0  0  0  0  0 12  0  0  0  0]
 [ 0  0  0  0  0  0  0  0  0  2 10  0  0  0]
 [ 0  0  0  0  0  0  0  0  0  0  0 11  1  0]
 [ 0  0  0  0  0  0  0  0  0  0  0  0 12  0]
 [ 0  0  0  0  0  0  0  1  0  0  0  0  0 11]]
```

	Lokasi	Accuracy	Precision	Recall	F1-Score
0	M1	1.000000	1.0	1.000000	1.000000
1	M2	1.000000	1.0	1.000000	1.000000
2	T1	1.000000	1.0	1.000000	1.000000
3	T2	1.000000	1.0	1.000000	1.000000
4	T3	0.833333	1.0	0.833333	0.909091
5	M3	1.000000	1.0	1.000000	1.000000
6	M4	1.000000	1.0	1.000000	1.000000
7	T4	0.916667	1.0	0.916667	0.956522
8	T5	1.000000	1.0	1.000000	1.000000
9	M5	0.916667	1.0	0.916667	0.956522
10	M6	0.833333	1.0	0.833333	0.909091
11	T6	0.916667	1.0	0.916667	0.956522
12	M7	0.750000	1.0	0.750000	0.857143
13	M8	0.916667	1.0	0.916667	0.956522

Hasil menunjukkan bahwa model mengklasifikasikan data dengan **akurasi 65%**. Sebagian besar lokasi memiliki akurasi, presisi, recall, dan F1-score sempurna (1.0), yang menandakan model mampu mengklasifikasikan data dengan sangat akurat. Namun, ada beberapa lokasi dengan skor di bawah 1 (**T3, M5, T4, T6, M6, M8**) : akurasinya masih sangat tinggi (di atas 0.83), menunjukkan sedikit kesalahan klasifikasi. **M7** memiliki performa paling rendah (akurasi 75%), yang bisa mengindikasikan adanya variasi data yang lebih tinggi atau jumlah data yang lebih sedikit.



ANALISIS DISKRIMINAN TEMPORAL


Cross-validation accuracy: 0.5245989304812835

Confusion Matrix:

```
[[ 9  5  0  0  0  0  0  0  0  0  0  0]
 [ 5  7  0  0  0  0  0  0  0  0  2  0]
 [ 0  0 14  0  0  0  0  0  0  0  0  0]
 [ 0  0  0 14  0  0  0  0  0  0  0  0]
 [ 0  0  0  0 14  0  0  0  0  0  0  0]
 [ 0  0  0  0  0 12  1  0  1  0  0  0]
 [ 0  0  0  0  1  0 12  1  0  0  0  0]
 [ 0  0  0  0  0  0  1  9  4  0  0  0]
 [ 0  0  0  0  0  0  1  4  9  0  0  0]
 [ 0  0  0  0  0  0  0  0  0 13  1  0]
 [ 0  0  0  0  0  0  0  0  0  0  9  5]
 [ 0  0  0  0  0  0  0  0  0  0  4 10]]
```

	Waktu	Accuracy	Precision	Recall	F1-Score
0	2019.07	0.642857	1.0	0.642857	0.782609
1	2019.08	0.500000	1.0	0.500000	0.666667
2	2019.09	1.000000	1.0	1.000000	1.000000
3	2019.10	1.000000	1.0	1.000000	1.000000
4	2019.11	1.000000	1.0	1.000000	1.000000
5	2019.12	0.857143	1.0	0.857143	0.923077
6	2020.01	0.857143	1.0	0.857143	0.923077
7	2020.03	0.642857	1.0	0.642857	0.782609
8	2020.04	0.642857	1.0	0.642857	0.782609
9	2020.05	0.928571	1.0	0.928571	0.962963
10	2020.06	0.642857	1.0	0.642857	0.782609
11	2020.07	0.714286	1.0	0.714286	0.833333

Hasil menunjukkan bahwa model mengklasifikasikan data dengan **akurasi 52,4%**. Kemudian dapat dilihat diperoleh performa yang sangat baik pada periode **2019.09** hingga **2019.11** dengan akurasi sempurna (100%). Namun, terdapat penurunan performa pada bulan-bulan tertentu seperti **2019.08**, **2020.03**, **2020.04**, dan **2020.06**, di mana akurasi hanya sekitar 64%-50%. Ini mengindikasikan bahwa model kurang konsisten dalam membedakan waktu tertentu, kemungkinan karena pola data yang mirip antar waktu tersebut atau jumlah data yang tidak seimbang. Performa model masih tergolong cukup baik secara umum.



Principal Component Analysis (PCA)



Principal Component Analysis (PCA)

Pengertian:

Principal Component Analysis adalah **teknik reduksi dimensi yang mengubah banyak variabel menjadi sejumlah kecil komponen utama** (principal components) yang masih mempertahankan sebagian besar informasi dalam data.

Tujuan:

- Menyederhanakan data kompleks menjadi beberapa komponen utama.
- Mengidentifikasi faktor-faktor dominan yang mempengaruhi kualitas air.



Pengujian Asumsi

1. Uji Kelayakan Data dengan Bartlett's Test of Sphericity

Uji Bartlett digunakan untuk menilai kelayakan data dalam analisis faktor dengan menguji apakah terdapat korelasi antar variabel. Apabila nilai $p < 0,05$, maka data dianggap layak untuk PCA maupun analisis faktor karena menunjukkan adanya hubungan antar variabel.

Hipotesis :

H_0 : Matriks korelasi sama dengan matriks identitas (tidak terdapat korelasi antar variabel).

H_1 : Matriks korelasi tidak sama dengan matriks identitas (terdapat korelasi antar variabel).

Taraf Signifikansi : 0.05

Daerah kritis :

Tolak H_0 jika $p.value < 0.05$

Statistik Uji :

```
===== Statistik Uji =====  
Chi-Square Bartlett      : 1306.42  
p-value                  : 0.00000
```

Keputusan & Kesimpulan :

```
===== Keputusan & Kesimpulan =====  
Keputusan   : Tolak  $H_0$ .  
Kesimpulan  : Terdapat korelasi antar variabel.
```

Dengan tingkat signifikansi 0.05 dan nilai p-value sebesar 0.0, maka keputusan yang diambil adalah **Tolak H_0** , yang berarti terdapat korelasi antar variabel sehingga data layak dilanjutkan untuk PCA maupun analisis faktor.



Pengujian Asumsi

2. Uji Kelayakan Data dengan KMO (Kaiser-Meyer-Olkin) Test

Uji KMO (Kaiser-Meyer-Olkin) digunakan untuk mengukur kecukupan sampel dalam analisis faktor; nilai $KMO > 0.5$ menunjukkan bahwa data memiliki korelasi parsial yang cukup dan layak untuk dianalisis lebih lanjut menggunakan PCA maupun analisis faktor.

Hipotesis :

H_0 : Data tidak layak dilanjutkan untuk PCA maupun analisis faktor.

H_1 : Data layak dilanjutkan untuk PCA maupun analisis faktor.

Daerah kritis :

Tolak H_0 jika nilai $KMO > 0.5$

Statistik Uji :

```
===== Nilai Statistik KMO =====  
Nilai KMO: 0.755
```

Keputusan & Kesimpulan :

```
===== Keputusan & Kesimpulan =====  
Keputusan : Tolak  $H_0$ .  
Kesimpulan : Data layak dilanjutkan untuk PCA maupun analisis faktor.
```

Karena nilai KMO sebesar $0.755 > 0.50$, maka keputusannya adalah **Tolak H_0** , yang berarti data layak dilanjutkan untuk PCA maupun analisis faktor.



Menentukan Jumlah Komponen Utama (PC)

1. Eigen Value

Salah satu cara menentukan jumlah komponen utama dalam PCA adalah dengan menggunakan **eigenvalues**. Komponen utama yang dipilih merupakan komponen utama yang memiliki **eigenvalues lebih dari satu**. **Eigenvalues** diperoleh dari **matriks covariance** atau **correlation** yang digunakan dalam PCA. **Eigenvalues** menunjukkan varians yang dijelaskan oleh masing-masing komponen utama.

```
# Menghitung eigenvalues
eigenvalues = pca.explained_variance_
```

```
# Menampilkan eigenvalues
print("Eigenvalues:")
print(eigenvalues)
```

Eigenvalues:

```
[5.58573081 2.01036622 1.76487272 1.37673644 1.0966594 1.04920579
 0.99063517 0.8831942 0.79152122 0.67374208 0.55199258 0.43706279
 0.3833235 0.33181017 0.29967358 0.2473134 0.23392732 0.22901433
 0.17699074]
```


Berdasarkan output dari eigenvalue di samping, terlihat bahwa jumlah komponen utama yang optimal dalam analisis ini adalah **6 kompone utama**. Hal tersebut dikarenakan 6 komponen utama pertama memiliki **eigenvalue lebih besar dari 1**, yang berarti masing-masing komponen dapat **menjelaskan lebih banyak variansi daripada satu variabel asli**.



Menentukan Jumlah Komponen Utama (PC)

2. Scree Plot

Jumlah komponen utama dalam PCA juga dapat ditentukan dengan menggunakan **Scree Plot**. Scree Plot merupakan plot yang menunjukkan **hubungan antara komponen utama ke-k dengan varians atau eigenvalues** pada komponen tersebut. Pemilihan jumlah komponen utama dilakukan berdasarkan **titik di mana terjadi penurunan tajam diikuti penurunan lebih landai**, yang menandakan kontribusi variansi yang lebih kecil.




Berdasarkan Scree Plot di samping, terlihat adanya perubahan kemiringan yang signifikan setelah **komponen utama ke-6** dan keenam komponen utama pertama memiliki **eigenvalues lebih dari satu (Kaiser Criterion)**. Sehingga, jumlah komponen utama yang optimal dalam PCA adalah **6**, karena dapat **menjelaskan sebagian besar variansi data** secara efisien.



Menentukan Jumlah Komponen Utama (PC)

3. Cumulative Explained Variance

Selain dengan eigenvalue dan Scree Plot, menentukan jumlah komponen utama dapat dilakukan dengan **cumulative explained variance**, yaitu total variansi yang dijelaskan oleh komponen. Umumnya digunakan **threshold $\geq 70\%$** , artinya jumlah komponen utama yang dipilih setidaknya harus **mampu menjelaskan minimal 70% dari total variansi dalam data** atau **menangkap sekitar 70% keragaman yang terdapat dalam data asli**.



Cumulative Explained Variance:

```
[0.29223592 0.39741485 0.48974998 0.56177849 0.61915384 0.6740465  
0.72587484 0.77208206 0.8134931 0.84874214 0.87762145 0.90048783  
0.92054266 0.9379024 0.95358081 0.96651983 0.97875851 0.99074015  
1. ]
```

Berdasarkan **Cumulative Explained Variance**, enam komponen utama menjelaskan **67,40% variansi data**. Meskipun belum mencapai 70%, pemilihan ini layak karena berdasarkan penentuan jumlah komponen dengan eigenvalue dan Scree Plot sebelumnya, **keenam komponen utama** telah **menjelaskan sebagian besar variansi data**.




Explained Variance & Proportion of Variance

- **Explained Variance** : jumlah variansi yang dijelaskan oleh setiap komponen utama dalam dataset yang diurutkan berdasarkan kontribusinya terhadap keseluruhan variansi data.
- **Proportion of Variance** : rasio antara explained variance sebuah komponen dan total variansi dalam data yang menggambarkan **kontribusi relatif komponen tersebut terhadap keseluruhan variansi**.

PC	Explained Variance	Proportion of Variance
PC1	5.585731	0.292236
PC2	2.010366	0.105179
PC3	1.764873	0.092335
PC4	1.376736	0.072029
PC5	1.096659	0.057375
PC6	1.049206	0.054893

Berdasarkan tabel di samping, PC1 memiliki nilai Explained Variance tertinggi, yaitu 5.59, yang menunjukkan bahwa komponen ini menjelaskan sebagian besar variansi dalam data, sekitar 29,22% (Proportion of Variance). Sementara itu, komponen-komponen berikutnya (PC2 hingga PC6) memiliki kontribusi yang lebih kecil, dengan Proportion of Variance masing-masing semakin menurun. PC2 menjelaskan 10,52% variansi, diikuti oleh PC3 (9,23%), PC4 (7,20%), PC5 (5,74%), dan PC6 (5,49%). Secara keseluruhan, **enam komponen tersebut telah menjelaskan sebagian besar variansi dalam data.**



Factor Analysis (FA)




Factor Analysis (FA)

Pengertian:

Factor Analysis adalah **metode statistik yang bertujuan untuk menemukan struktur hubungan antar variabel** dengan mengidentifikasi faktor-faktor laten (tidak teramati) yang mempengaruhi variabel-variabel tersebut.

Tujuan:

- Menemukan faktor penyebab utama perubahan kualitas air.
- Membantu memahami struktur hubungan antar parameter kualitas air.



Factor Analysis (FA)

Tanpa Reduksi



Pengujian Asumsi

Uji Kelayakan Variabel dengan Nilai MSA pada Uji KMO

Setelah data dinyatakan layak untuk PCA dan analisis faktor melalui Uji Bartlett dan KMO, dilakukan pemeriksaan nilai MSA tiap variabel dari Uji KMO. Variabel dengan nilai $MSA > 0.50$ dianggap layak untuk dianalisis lebih lanjut dalam analisis faktor.

Hipotesis :

H₀ : Variabel tidak layak untuk dianalisis lebih lanjut dalam analisis faktor.

H₁ : Variabel layak untuk dianalisis lebih lanjut dalam analisis faktor.

Daerah kritis :

Tolak H₀ jika nilai $MSA > 0.50$

Statistik Uji & Keputusan :

Nilai KMO (keseluruhan): 0.755			
	Variabel	Nilai MSA	Kelayakan
0	PH	0.531521	Layak
1	DO	0.615273	Layak
2	COD	0.845093	Layak
3	NH ₃ -N	0.703837	Layak
4	TP	0.872126	Layak
5	CODMn	0.842443	Layak
6	F	0.556333	Layak
7	Oil	0.680936	Layak
8	Cr ₆₊	0.777592	Layak
9	LAS	0.560899	Layak
10	Cu	0.816584	Layak
11	Zn	0.721911	Layak
12	Cd	0.675133	Layak
13	As	0.766855	Layak
14	Hg	0.753791	Layak
15	CN	0.822131	Layak
16	VP	0.826538	Layak
17	S	0.780013	Layak
18	Se	0.550704	Layak

Kesimpulan :

Dikarenakan semua variabel memiliki nilai $MSA > 0.50$, maka dapat disimpulkan bahwa semua variabel parameter kualitas air layak untuk dianalisis lebih lanjut dalam analisis faktor.



Menentukan Jumlah Faktor

1. Eigen Value & Cumulative Variance Explained

Tabel Eigenvalue dan Variansi:


	Component	Eigenvalue	% of Variance	Cumulative %
0	F1	5.585731	29.223592	29.223592
1	F2	2.010366	10.517893	39.741485
2	F3	1.764873	9.233513	48.974998
3	F4	1.376736	7.202850	56.177849
4	F5	1.096659	5.737535	61.915384
5	F6	1.049206	5.489266	67.404650
6	F7	0.990635	5.182834	72.587484
7	F8	0.883194	4.620722	77.208206
8	F9	0.791521	4.141104	81.349310
9	F10	0.673742	3.524904	84.874214
10	F11	0.551993	2.887931	87.762145
11	F12	0.437063	2.286638	90.048783
12	F13	0.383324	2.005483	92.054266
13	F14	0.331810	1.735974	93.790240
14	F15	0.299674	1.567841	95.358081
15	F16	0.247313	1.293902	96.651983
16	F17	0.233927	1.223868	97.875851
17	F18	0.229014	1.198164	99.074015
18	F19	0.176991	0.925985	100.000000

- Sama seperti PCA, faktor yang terpilih adalah **F1, F2, F3, F4, F5, dan F6** karena memiliki **eigenvalue > 1** (Kaiser Criterion) dengan eigenvalue masing-masing 5.58, 2.01, 1.76, 1.38, 1.10, dan 1.05.
- F1 menjelaskan 29.22% dari variansi, diikuti oleh F2 dengan 10.51%, F3 dengan 9.23%, F4 dengan 7.20%, F5 dengan 5.73%, dan F6 dengan 5.49%.
- Keenam faktor bersama-sama menjelaskan **67.40% dari total variansi dalam data**, yang berarti keempat faktor ini sudah cukup **mewakili lebih dari setengah variansi** atau **sebagian besar informasi dalam data**.



Menentukan Jumlah Faktor

2. Scree Plot



- Seperti pada PCA, Scree Plot menunjukkan adanya perubahan kemiringan yang signifikan setelah **faktor ke-6** dan **keenam faktor pertama** memiliki **eigenvalues > 1** (Kaiser Criterion).
- Sehingga, **jumlah faktor yang optimal dalam analisis faktor adalah 6**, karena dapat menjelaskan **sebagian besar variansi data secara efisien**.



Loading Faktor & Pengelompokan Faktor

Loading Faktor :

```
FactorAnalyzer
FactorAnalyzer(n_factors=6, rotation='varimax', rotation_kwargs={})
```

Factor Loadings dan Variance Explained dengan Rotasi Varimax						
	VF1	VF2	VF3	VF4	VF5	VF6
PH	-0.208	0.008	0.082	-0.062	-0.075	0.554
DO	-0.279	-0.111	0.022	0.156	-0.174	-0.033
COD	0.328	0.487	0.232	0.185	0.346	-0.019
NH3-N	0.450	0.222	0.223	-0.325	-0.291	-0.029
TP	0.610	0.371	0.176	-0.004	-0.035	-0.112
CODMn	0.238	0.739	0.196	-0.007	0.031	-0.131
F	-0.005	0.183	0.112	0.978	0.109	0.042
Oil	0.210	0.398	0.033	0.313	0.122	0.240
Cr6+	0.180	0.658	-0.001	0.143	0.336	-0.120
LAS	0.385	-0.040	0.115	0.153	0.015	0.697
Cu	0.786	0.105	0.059	0.192	0.108	-0.074
Zn	0.134	0.232	0.123	-0.036	-0.021	-0.325
Cd	0.017	0.147	0.103	0.083	0.683	-0.035
As	0.320	0.212	0.426	0.195	0.352	-0.006
Hg	0.515	0.111	-0.087	-0.043	0.226	-0.242
CN	0.521	0.228	0.039	0.050	0.453	-0.031
VP	0.572	0.442	-0.070	-0.014	0.281	-0.039
S	0.753	0.181	0.173	0.013	-0.107	0.124
Se	0.024	0.130	0.982	0.048	0.082	0.108
Eigenvalue	5.552	1.998	1.754	1.369	1.090	1.043
% Variance	29.224	10.518	9.234	7.203	5.738	5.489
Cumulative %	29.224	39.741	48.975	56.178	61.915	67.405

Pengelompokan Faktor :

Hasil Pengelompokan Faktor

	VF1	VF2	VF3	VF4	VF5	VF6
0	TP	CODMn	Se	F	Cd	PH
1	Cu	Cr6+	-	-	-	LAS
2	Hg	-	-	-	-	-
3	CN	-	-	-	-	-
4	VP	-	-	-	-	-
5	S	-	-	-	-	-



Interpretasi & Penamaan Faktor Terbentuk

Faktor 1

Polusi Logam Berat & Limbah Domestik

Menunjukkan faktor pencemaran kualitas air yang berasal dari **limbah domestik (TP, CN, VP)** serta **logam berat dari aktivitas industri atau metalurgi (Cu, Hg, S)**.

- TP $\rightarrow$ 0.610
- Cu $\rightarrow$ 0.786
- CN $\rightarrow$ 0.521
- Hg $\rightarrow$ 0.515
- VP $\rightarrow$ 0.572
- S $\rightarrow$ 0.753

Seluruh variabel pada faktor 1 menunjukkan **hubungan positif** sehingga **kenaikan nilai tiap variabel** akan bersamaan dengan **peningkatan nilai faktor**.

Faktor 2

Polusi Kimia Industri

Menunjukkan faktor pencemaran kualitas air yang berasal dari **limbah industri kimia**, ditandai dengan tingginya **kebutuhan oksigen kimia (CODMn)** serta keberadaan **logam berat beracun (Cr^{6+})**

- CODMn $\rightarrow$ 0.739
- Cr^{6+} $\rightarrow$ 0.658

Seluruh variabel pada faktor 2 menunjukkan **hubungan positif** sehingga **kenaikan nilai tiap variabel** akan bersamaan dengan **peningkatan nilai faktor**.



Interpretasi & Penamaan Faktor Terbentuk

Faktor 3

Kontaminasi Unsur Beracun

Menunjukkan kontaminasi spesifik dari **Selenium** yang merupakan **unsur toksik** yang bisa berasal dari **limbah elektronik, manufaktur baja, atau pupuk**. Keberadaan Se menunjukkan **risiko tinggi bagi kesehatan dan ekosistem** karena sifatnya yang **toksik** dan **mudah terakumulasi meski dalam kadar rendah**.

- $Se \rightarrow 0.982$

Variabel Selenium (Se) pada faktor 3 menunjukkan **hubungan positif yang sangat kuat** sehingga **kenaikan nilai tiap variabel** akan bersamaan dengan **peningkatan nilai faktor**.

Faktor 4

Polusi Anorganik & Fluorida

Menunjukkan faktor pencemaran kualitas air dari **Fluorida (F)** yang dapat berasal dari **industri kimia, pupuk, atau limbah tekstil**. Kandungan F yang tinggi dapat mencerminkan **kontaminasi gabungan** antara **sumber alami** dan **aktivitas manusia (antropogenik)**.

- $F \rightarrow 0.978$

Variabel Fluorida (F) pada faktor 4 menunjukkan **hubungan positif yang sangat kuat** sehingga **kenaikan nilai tiap variabel** akan bersamaan dengan **peningkatan nilai faktor**.



Interpretasi & Penamaan Faktor Terbentuk

Faktor 5

Kontaminasi Logam Berat Berbahaya

Menunjukkan **kontaminasi spesifik dari Cadmium (Cd)** yang merupakan **logam berat berbahaya** yang sering ditemukan pada **limbah elektronik, proses galvanisasi logam, dan baterai bekas**. Keberadaan Cd dalam air menandakan **pencemaran berisiko tinggi** bagi ekosistem dan manusia karena toksisitas dan bioakumulasi.

- Cd $\rightarrow$ 0.683

Variabel Cadmium (Cd) pada faktor 5 menunjukkan **hubungan positif** sehingga **kenaikan nilai tiap variabel** akan bersamaan dengan **peningkatan nilai faktor**.


Faktor 6

Polusi Rumah Tangga (Deterjen)

Menunjukkan faktor pencemaran kualitas air terkait **variasi pH** dengan kehadiran **Linear Alkylbenzene Sulfonate (LAS)**, **bahan aktif dalam deterjen**. Ini mencerminkan **polusi domestik** yang memengaruhi **keasaman air** serta **kualitas biologisnya**.

- PH $\rightarrow$ 0.554
- LAS $\rightarrow$ 0.697

Seluruh variabel pada faktor 6 menunjukkan **hubungan positif** sehingga **kenaikan nilai tiap variabel** akan bersamaan dengan **peningkatan nilai faktor**.



Factor Analysis (FA)

Dengan Reduksi



Pengujian Asumsi

Uji Kelayakan Variabel dengan Nilai MSA pada Uji KMO

Setelah data dinyatakan layak untuk PCA dan analisis faktor melalui Uji Bartlett dan KMO, dilakukan pemeriksaan nilai MSA tiap variabel dari Uji KMO. Untuk mendapatkan hasil yang lebih baik, variabel dengan nilai MSA > 0.60 dianggap cukup baik untuk dianalisis lebih lanjut dalam analisis faktor.

Hipotesis :

H₀ : Variabel tidak cukup baik untuk dianalisis lebih lanjut dalam analisis faktor.

H₁ : Variabel cukup baik untuk dianalisis lebih lanjut dalam analisis faktor.

Daerah kritis :

Tolak H₀ jika nilai MSA > 0.60

Statistik Uji & Keputusan :

Nilai KMO (keseluruhan): 0.755			
	Variabel	Nilai MSA	Kelayakan
0	PH	0.531521	Tidak Layak
1	DO	0.615273	Layak
2	COD	0.845093	Layak
3	NH ₃ -N	0.703837	Layak
4	TP	0.872126	Layak
5	CODMn	0.842443	Layak
6	F	0.556333	Tidak Layak
7	Oil	0.680936	Layak
8	Cr ₆₊	0.777592	Layak
9	LAS	0.560899	Tidak Layak
10	Cu	0.816584	Layak
11	Zn	0.721911	Layak
12	Cd	0.675133	Layak
13	As	0.766855	Layak
14	Hg	0.753791	Layak
15	CN	0.822131	Layak
16	VP	0.826538	Layak
17	S	0.780013	Layak
18	Se	0.550704	Tidak Layak

Kesimpulan :

Dikarenakan semua variabel memiliki nilai MSA > 0.60 , maka dapat disimpulkan bahwa semua variabel parameter kualitas air layak untuk dianalisis lebih lanjut dalam analisis faktor.



Reduksi Variabel

- **Reduksi variabel** merupakan **proses mengurangi jumlah variabel dalam dataset pada analisis faktor** dengan tetap mempertahankan informasi yang paling relevan. R
- **Reduksi variabel** dilakukan dengan **menghapus variabel dengan MSA di bawah 0.6** karena dianggap **tidak cukup baik** untuk analisis faktor dan harus dipertimbangkan untuk dihapus.
- Variabel dengan $MSA < 0.6$ akan **direduksi secara bertahap** dengan **menghapus yang terendah** hingga semua variabel yang tersisa memenuhi kriteria $MSA > 0.6$.

Mengeluarkan Variabel "PH" :

Variabel 'PH' dikeluarkan.			
Nilai KMO keseluruhan setelah reduksi: 0.762			
	Variabel	Nilai MSA	Kelayakan
0	DO	0.666836	Cukup Baik
1	COD	0.842001	Cukup Baik
2	NH3-N	0.707134	Cukup Baik
3	TP	0.879832	Cukup Baik
4	CODMn	0.840762	Cukup Baik
5	F	0.566282	Tidak Cukup Baik
6	Oil	0.671898	Cukup Baik
7	Cr6+	0.777573	Cukup Baik
8	LAS	0.597762	Tidak Cukup Baik
9	Cu	0.813864	Cukup Baik
10	Zn	0.679723	Cukup Baik
11	Cd	0.670468	Cukup Baik
12	As	0.770408	Cukup Baik
13	Hg	0.734287	Cukup Baik
14	CN	0.826482	Cukup Baik
15	VP	0.822635	Cukup Baik
16	S	0.782453	Cukup Baik
17	Se	0.543336	Tidak Cukup Baik

Mengeluarkan Variabel "Se" :

Variabel 'Se' dikeluarkan.			
Nilai KMO keseluruhan setelah reduksi: 0.779			
	Variabel	Nilai MSA	Kelayakan
0	DO	0.661196	Cukup Baik
1	COD	0.828932	Cukup Baik
2	NH3-N	0.688131	Cukup Baik
3	TP	0.885996	Cukup Baik
4	CODMn	0.848124	Cukup Baik
5	F	0.548604	Tidak Cukup Baik
6	Oil	0.696423	Cukup Baik
7	Cr6+	0.767683	Cukup Baik
8	LAS	0.586164	Tidak Cukup Baik
9	Cu	0.821564	Cukup Baik
10	Zn	0.686665	Cukup Baik
11	Cd	0.691283	Cukup Baik
12	As	0.808192	Cukup Baik
13	Hg	0.792518	Cukup Baik
14	CN	0.820740	Cukup Baik
15	VP	0.840917	Cukup Baik
16	S	0.798649	Cukup Baik



Reduksi Variabel

Mengeluarkan Variabel "F" :

Variabel 'F' dikeluarkan.			
Nilai KMO keseluruhan setelah reduksi: 0.798			
	Variabel	Nilai MSA	Kelayakan
0	DO	0.792720	Cukup Baik
1	COD	0.817683	Cukup Baik
2	NH3-N	0.764737	Cukup Baik
3	TP	0.880553	Cukup Baik
4	CODMn	0.839512	Cukup Baik
5	Oil	0.711707	Cukup Baik
6	Cr6+	0.751468	Cukup Baik
7	LAS	0.552295	Tidak Cukup Baik
8	Cu	0.864770	Cukup Baik
9	Zn	0.729067	Cukup Baik
10	Cd	0.678056	Cukup Baik
11	As	0.792033	Cukup Baik
12	Hg	0.829193	Cukup Baik
13	CN	0.814511	Cukup Baik
14	VP	0.840787	Cukup Baik
15	S	0.793950	Cukup Baik

Mengeluarkan Variabel "LAS" :

Variabel 'LAS' dikeluarkan.			
Nilai KMO keseluruhan setelah reduksi: 0.816			
	Variabel	Nilai MSA	Kelayakan
0	DO	0.790481	Cukup Baik
1	COD	0.844196	Cukup Baik
2	NH3-N	0.777586	Cukup Baik
3	TP	0.874154	Cukup Baik
4	CODMn	0.865687	Cukup Baik
5	Oil	0.765068	Cukup Baik
6	Cr6+	0.753579	Cukup Baik
7	Cu	0.862205	Cukup Baik
8	Zn	0.827717	Cukup Baik
9	Cd	0.695032	Cukup Baik
10	As	0.782090	Cukup Baik
11	Hg	0.835242	Cukup Baik
12	CN	0.823497	Cukup Baik
13	VP	0.836505	Cukup Baik
14	S	0.778648	Cukup Baik

Setelah 4 variabel parameter kualitas air yaitu **"PH"**, **"Se"**, **"F"**, dan **"LAS"** direduksi, **tersisa 15 dari 19 variabel parameter kualitas air** yang sudah **memenuhi kriteria cukup baik** dengan **nilai MSA > 0.60**.



Menentukan Jumlah Faktor

1. Eigen Value & Cumulative Variance Explained

Tabel Eigenvalue dan Cumulative Variance Explained:


	Factor Component	Eigenvalue	% of Variance	Cumulative %
0	F1	5.310527	35.192775	35.192775
1	F2	1.661076	11.007925	46.200701
2	F3	1.161112	7.694668	53.895368
3	F4	1.035064	6.859350	60.754718
4	F5	0.964667	6.392831	67.147549
5	F6	0.896031	5.937983	73.085532
6	F7	0.735478	4.873998	77.959531
7	F8	0.697152	4.620016	82.579547
8	F9	0.579321	3.839154	86.418701
9	F10	0.505775	3.351761	89.770462
10	F11	0.431895	2.862163	92.632625
11	F12	0.349268	2.314593	94.947218
12	F13	0.308734	2.045975	96.993194
13	F14	0.251344	1.665651	98.658845
14	F15	0.202378	1.341155	100.000000

- Faktor yang terpilih adalah **F1, F2, F3, dan F4** karena memiliki **eigenvalue** > 1 (Kaiser Criterion) dengan eigenvalue masing-masing 5.31, 1.66, 1.16, dan 1.04.
- F1 menjelaskan 35.19% dari variansi, diikuti oleh F2 dengan 11.01%, F3 dengan 7.69%, dan F4 dengan 6.86%.
- Keempat faktor ini bersama-sama menjelaskan **60.75% dari total variansi dalam data**, yang berarti keempat faktor ini sudah cukup **mewakili lebih dari setengah variansi** atau **sebagian besar informasi dalam data**.




Menentukan Jumlah Faktor

2. Scree Plot



- Scree Plot menunjukkan adanya perubahan kemiringan yang signifikan setelah **faktor ke-4** dan **kempat faktor pertama** memiliki **eigenvalues > 1** (Kaiser Criterion).
- Sehingga, **jumlah faktor yang optimal dalam analisis faktor adalah 4**, karena dapat menjelaskan **sebagian besar variansi data secara efisien**.





Loading Faktor & Pengelompokan Faktor

Loading Faktor :

```
FactorAnalyzer
FactorAnalyzer(n_factors=4, rotation='varimax', rotation_kwarg={})
```

Factor Loadings dan Variance Explained dengan Rotasi Varimax :

	VF1	VF2	VF3	VF4
DO	-0.283	-0.118	-0.047	0.003
COD	0.348	0.554	0.321	-0.084
NH3-N	0.216	0.210	0.072	0.569
TP	0.568	0.406	-0.007	0.318
CODMn	0.221	0.710	0.108	0.181
Oil	0.187	0.338	0.237	-0.014
Cr6+	0.211	0.758	0.152	-0.163
Cu	0.644	0.209	0.186	0.205
Zn	0.123	0.253	0.025	0.130
Cd	0.225	0.269	0.196	-0.517
As	0.216	0.239	0.946	-0.014
Hg	0.445	0.159	0.233	0.079
CN	0.728	0.216	0.156	-0.210
VP	0.698	0.407	0.033	-0.012
S	0.656	0.095	0.207	0.459
Eigenvalue	5.279	1.651	1.154	1.029
% Variance	35.193	11.008	7.695	6.859
Cumulative %	35.193	46.201	53.895	60.755

Pengelompokan Faktor :

Hasil Pengelompokan Faktor

	VF1	VF2	VF3	VF4
0	TP	COD	As	NH3-N
1	Cu	CODMn	-	Cd
2	CN	Cr6+	-	-
3	VP	-	-	-
4	S	-	-	-



Interpretasi & Penamaan Faktor Terbentuk

Faktor 1

Polusi Logam Berat & Limbah Domestik

Menunjukkan faktor pencemaran kualitas air yang berasal dari campuran antara polutan organik dari **limbah domestik (TP, CN, VP)** dan unsur **logam berat** dari aktivitas industri/logam (**Cu, S**).

- TP → 0.568
- Cu → 0.644
- CN → 0.728
- VP → 0.698
- S → 0.656

Seluruh variabel pada faktor 1 menunjukkan **hubungan positif** sehingga **kenaikan nilai tiap variabel** akan bersamaan dengan **peningkatan nilai faktor**.

Faktor 2

Polusi Kimia Industri

Menunjukkan faktor pencemaran kualitas air yang berasal dari **limbah industri kimia**, ditandai dengan tingginya **kebutuhan oksigen kimia (COD, CODMn)** serta keberadaan **logam berat beracun (Cr⁶⁺)**

- COD → 0.554
- CODMn → 0.710
- Cr⁶⁺ → 0.758

Seluruh variabel pada faktor 2 menunjukkan **hubungan positif** sehingga **kenaikan nilai tiap variabel** akan bersamaan dengan **peningkatan nilai faktor**.



Interpretasi & Penamaan Faktor Terbentuk

Faktor 3

Kontaminasi Arsenik

Menunjukkan kontaminasi spesifik dari **arsenik** yang dapat berasal dari pertambangan atau industri kimia. Peningkatan konsentrasi arsenik dalam air sungai dapat mengindikasikan adanya pencemaran yang terkait dengan aktivitas industri atau pertambangan.

- As $\rightarrow$ 0.946

Variabel Arsenik (AS) pada faktor 3 menunjukkan **hubungan positif yang sangat kuat** sehingga **kenaikan nilai tiap variabel akan bersamaan dengan peningkatan nilai faktor**.

Faktor 4

Polusi Limbah Rumah Tangga & Industri

Menunjukkan faktor pencemaran kualitas air yang berasal dari campuran **limbah rumah tangga (NH₃-N)** dan logam berat yang terkait dengan **aktivitas industri (Cd)**.

- NH₃-N $\rightarrow$ 0.569
- Cd $\rightarrow$ -0.517

Variabel **NH₃-N** menunjukkan **hubungan positif** dengan **peningkatan nilai faktor**, sedangkan variabel **Cd** menunjukkan **hubungan negatif** dalam **peningkatan nilai faktor**.




Analisis Cluster Pada Data Hasil Analisis Faktor




Analisis Cluster Spasial

Metode Elbow



Dengan menggunakan metode Elbow didapatkan jumlah cluster pada klaster spasial yaitu 3 cluster

Klasterisasi Spasial berdasarkan PCA






Metode Elbow

Analisis Cluster Spasial

	Lokasi	Cluster_Spasial
0	M1	2
1	M2	1
2	M3	1
3	M4	0
4	M5	0
5	M6	0
6	M7	0
7	M8	0
8	T1	2
9	T2	1
10	T3	1
11	T4	1
12	T5	1
13	T6	0



Cluster 0

- M4
- M5
- M6
- M7
- M8
- T6

Cluster 1

- M2
- M3
- T2
- T3
- T4
- T5

Cluster 2


- M1
- T1

Semakin panjang garis antar data artinya semakin berbeda antar data/cluster sebaliknya jika semakin pendek artinya semakin mirip. Berdasarkan dendrogram spasial cluster yang dihasilkan adalah 3 cluster



Analisis Cluster Temporal


Metode Elbow



Dengan menggunakan metode Elbow didapatkan jumlah cluster pada cluster temporal yaitu 2 cluster

	Bulan	Cluster
0	2019.07	2
1	2019.08	2
2	2019.09	1
3	2019.10	2
4	2019.11	1
5	2019.12	1
6	2020.01	1
7	2020.02	1
8	2020.03	1
9	2020.06	1
10	2020.07	2
11	2020.08	2

Semakin panjang garis antar data artinya semakin berbeda antar data/cluster sebaliknya jika semakin pendek artinya semakin mirip. Berdasarkan dendrogram temporal cluster yang dihasilkan adalah 2 cluster/kelompok data.



Cluster 1

- 2019.09
- 2019.11
- 2019.12
- 2020.01
- 2020.02
- 2020.03
- 2020.06

Cluster 2

- 2019.07
- 2019.08
- 2019.10
- 2020.07
- 2020.08



Kesimpulan

Dilakukan analisis faktor dengan dua kondisi :

a. **Analisis faktor tanpa reduksi**

- Terbentuk **enam faktor**, yaitu faktor polusi logam berat & limbah domestik (**TP, Cu, Hg, CN, VP, S**), faktor kimia industri (**CODMn, Cr6+**), faktor kontaminasi unsur beracun (**Se**), faktor anorganik dan flourida (**F**), faktor kontaminasi logam berat berbahaya (**Cd**), serta terakhir faktor limbah rumah tangga (detergen) (**PH, LAS**) yang dapat menjelaskan varians sebesar **67,40%**.

b. **Analisis faktor dengan reduksi**

- Terbentuk **empat faktor**, yaitu faktor polusi logam berat & limbah domestik (**TP, Cu, CN, VP, S**), faktor kimia industri (**COD, CODMn, Cr6+**), faktor kontaminasi arsenik (**As**), serta faktor limbah rumah tangga & industri (**NH3-N dan Cd**) yang dapat menjelaskan varians sebesar **60,75%**.



Kesimpulan

- Berdasarkan analisis tersebut diperoleh hasil **analisis faktor terbaik** yaitu yang **tanpa reduksi** karena dapat menjelaskan variansi sebesar **67.40%** dari total variansi dalam data, yang berarti **keenam faktor** yang diperoleh sudah cukup **mewakili lebih dari setengah variansi** atau **sebagian besar informasi dalam data**.
- Pengelompokan berdasarkan spasial (tempat pengambilan sampel air) didapatkan 3 cluster, yaitu **Cluster jauh dari batas kota (M1 dan T1), Cluster tidak terlalu jauh atau terlalu dekat batas kota (M2, M3, T2, T3, T4 dan T5), Cluster dekat batas kota (M4, M5, M6, M7, M8 dan T6)**.
- Pengelompokan berdasarkan temporal (waktu pengambilan sampel air) didapatkan 2 cluster, yaitu **Musim Gugur & Musim Dingin (September 2019 - Maret 2020 & Juni 2020), Musim Semi & Musim Panas (Juli - Oktober 2019 dan Juli - Agustus 2020)**



Terima Kasih